실험 setting

Base model 성능

DATASET	ACCURACY
MNIST	0.9874
CIFAR10	0.8735

Attack 방식

FGSM	targeted
	untargeted
PGD	targeted
	untargeted

Attack시 사용한, Loss Functions

Loss Function	표기
Cross Entropy	ce
Mean Squared Error	mse
KL Divergence	kl
Margin Loss	margin

* margin

: 정답 클래스 logit과 가장 큰 오답 클래스 logit 차이값으로 정의

$$m(x) = z_y - \max_{j \neq y} z_j$$

실험에 사용한 parameter

ε	1e-4, 1e-3, 0.01, 0.03, 0.05, 0.1, 0.15, 0.2, 0.25, 0.3, 0.4, 0.5
pgd_iteration_steps	10, 20, 30, 40, 50, 60

결과 및 결과 분석

DATASET별 적대적 공격 성공률 곡선 (vs. ε)

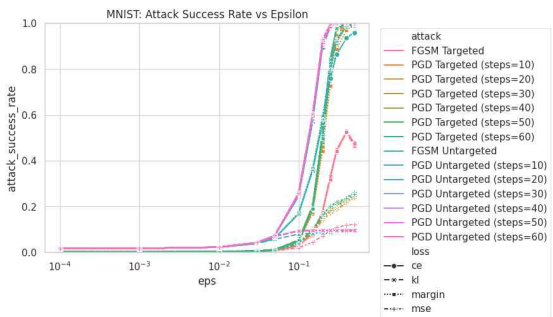

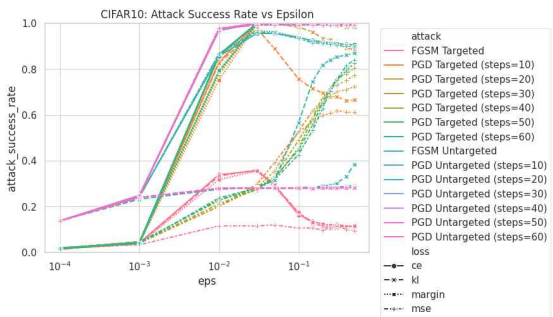

결과 분석

CIFAR-10에서의 attack이 MNIST보다 작은 ε에서부터 이뤄진다.

MNIST와 CIFAR-10의 결과를 비교해보면, CIFAR-10은 MNIST보다 더 작은 ε에서부터 공격이 성공하는 경향을 보인다. 마지막 hidden layer의 feature를 PCA로 시각화한 결과, CIFAR-10은 MNIST에 비해 클래스 간 feature overlap이 크게 나타남을 볼 수 있다. 이는, CIFAR-10의 decision boundary가 상대적으로 더 복잡하고, 밀집되어 있어, 작은 perturbation만으로도 boundary를 넘기기 쉬운 구조임을 의미한다. 따라서, 작은 perturbation만으로도 feature가 인접한 다른 클래스 영역으로 이동하기 쉬워, 더 작은 ε에서도 공격이 성공한 것으로 파악된다.

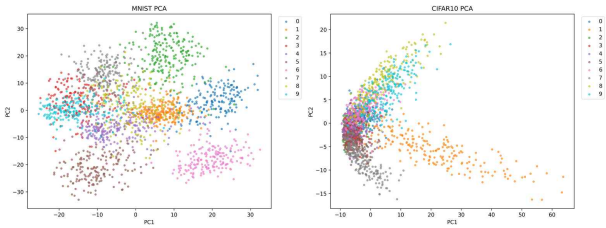

Untargeted 공격이 Targeted 공격보다 훨씬 높은 성공률을 보인다.

이는 특정 목표 클래스로 정확히 유도할 필요 없이, 현재 decision boundary를 벗어나기만 하면 되기 때문에 더 쉽게 성공하는 것으로 파악된다.

target attack은 ε이 증가함에 따라, 일정 수준 이상의 ε을 넘어서면, 감소하는 경향이 보이는 경우도 있다.

이는 perturbation이 과도해지면서 목표 클래스가 아닌 다른 클래스 영역으로 이동하는 경우가 증가하기 때문으로 판단된다.

target attack의 경우, 목표 클래스로 예측했을 때, 공격 성공으로 측정되기에 기존 클래스를 벗어났더라도, 목표 클래스로 가지 못하면, 공격 성공으로 집계되지 않는다.

target attack에서는 성공률이 높고, untarget attack에서는 성공률이 부진한 KL loss

4가지 loss를 이용해서 실험을 진행해 보았는데, target attack의 성공률은 KL loss를 사용할 때 높은 것을 볼 수 있다. 이는 목표 클래스의 확률 분포를 직접 모사하도록 유도함으로써 공격의 방향성을 안정적으로 확보했기 때문으로 파악된다. 반대로 untargeted 공격에서의 상대적인 부진은 전체 확률 분포를 정렬하려는 KL Loss의 특성에서 기인한다고 볼 수 있다. 단순히 현재 클래스를 이탈시키는 것이 목적인 경우에는 분포 정렬에 집중하는 KL Loss가 CE나 Margin Loss에 비해 decision boundary를 직접적으로 밀어내는 힘이 약해, 공격의 직접성이 상대적으로 떨어지는 것으로 파악된다.

PGD step 수가 증가할수록 targeted 공격 성능이 향상됨을 볼 수 있다. 이는 반복적인 gradient update를 통해 목표 클래스 방향으로 더 정밀하게 feature를 이동시킬 수 있어, 단일 step보다 목표 클래스 영역에 안정적으로 도달하기 쉬워지기 때문으로 파악된다.

MNIST 결과 그래프

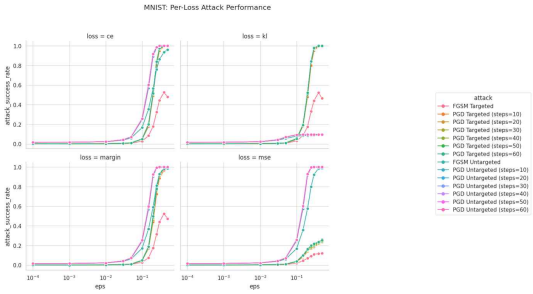

PGD

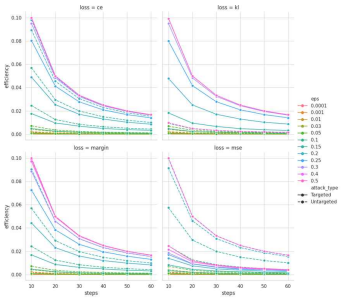

* efficiency = attack 성공률 / step수

CIFAR10 결과 그래프

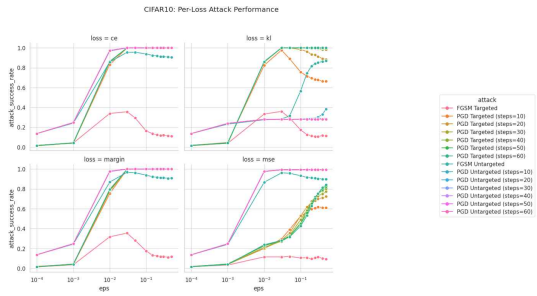

PGD

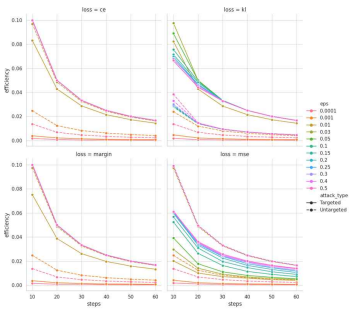

* efficiency = attack 성공률 / step수

MNIST, cross entropy loss				
ε	0.001	0.01	0.1	0.3
FGSM targeted	0.01672	0.00250	0.02797	0.44578
FASM untargeted	0.01672	0.02172	0.16688	0.86328
PGD targeted (steps=60)	0.00172	0.00141	0.04906	0.97484
PGD untargeted (steps=60)	0.01672	0.02203	0.25828	0.99921

CIFAR-10, cross entropy loss				
ε	0.001	0.01	0.1	0.3
FGSM targeted	0.04109	0.33906	0.16281	0.12203
FASM untargeted	0.24109	0.85641	0.93844	0.91141
PGD targeted (steps=60)	0.04234	0.86234	1.0	1.0
PGD untargeted (steps=60)	0.24750	0.97313	1.0	1.0

예시 시각화

loss function : cross entropy loss, PGD steps = 60

초록색 : attack 성공, 빨간색 : attack 실패

ε은 공격 성공률과 시각적 왜곡 사이의 trade-off를 결정하는 핵심 요소이다. ε이 커질수록 decision boundary를 더 쉽게 넘을 수 있어 일반적으로 공격 성공률은 증가하지만, perturbation이 눈에 띄게 커져 이미지 훼손도 심해진다. 반대로 작은 ε은 이미지 품질은 유지되지만 공격 성공률은 낮아질 수 있다. 하지만 targeted 공격의 경우 ε이 지나치게 커지면 목표 클래스의 decision region을 넘어 다른 클래스 영역까지 이동하여, 오히려 target 성공률이 감소하는 현상도 관찰되었다.